

Proyecto:

El Factor D10S: Datos que predicen el abandono escolar antes de jugar el tiempo suplementario

¿Dónde estamos parados?

En Ciencia de Datos, aproximadamente el **70-80% del tiempo** de un proyecto se dedica a la obtención, limpieza e integración de datos. Aunque esta etapa suele ser la menos vistosa, es una de las más importantes: la calidad del modelo dependerá directamente de la calidad de los datos utilizados.

En esta primera entrega nos concentraremos en construir una base sólida sobre la cual desarrollaremos el resto del proyecto.

Objetivo

Construir un dataset analítico a nivel estudiante, enriquecido con indicadores socioeconómicos contextuales obtenidos a partir de la Encuesta Permanente de Hogares (EPH).

Como resultado de esta etapa se obtendrá un **dataset maestro inicial**, compuesto por un conjunto reducido de variables estratégicas que servirán de base para las etapas posteriores de análisis exploratorio, ingeniería de variables y modelado predictivo del abandono escolar.

Fuentes de datos

Pruebas Aprender

- Portal de Datos Abiertos de Argentina
- <https://datos.gob.ar>

Encuesta Permanente de Hogares (EPH)

- INDEC
- <https://www.indec.gob.ar/indec/web/Institucional-Indec-BasesDeDatos-1>

Alcance

Durante esta primera entrega se trabajará únicamente sobre las variables consideradas esenciales para la integración de ambas fuentes, priorizando aquellas que permitan establecer equivalencias entre los datos educativos y los datos socioeconómicos.

No se incorporarán aún variables derivadas ni procesos avanzados de imputación o transformación.

Variables a conservar

Identificación territorial

- Jurisdicción

Características de la institución

- Sector (público/privado)
- Ámbito (urbano/rural)

Características del estudiante

- Edad
- Sexo
- Sobreedad

Rendimiento académico

- Desempeño en Lengua
- Desempeño en Matemática

Contexto socioeconómico

- Nivel socioeconómico
- Educación de la madre, padre o referente
- Tamaño del hogar
- Cantidad de libros en el hogar
- Horas de estudio
- Inasistencias

Actividades a desarrollar

1. **Descargar las bases de datos** correspondientes a las Pruebas Aprender 2024 (Nivel Secundario) y a la Encuesta Permanente de Hogares (EPH) del tercer trimestre de 2024.
2. **Integrar las tablas Viviendas y Personas de la EPH** mediante el identificador común (**CODUSU**), obteniendo una única base de datos con información del hogar y de sus integrantes.
3. **Analizar la estructura de ambas fuentes**, identificando la unidad de análisis, el nivel geográfico y las variables disponibles en cada una.
4. **Seleccionar las variables de interés** de ambas bases, priorizando aquellas relevantes para el estudio del abandono escolar.
5. Identificar las variables de integración entre ambas fuentes, definiendo el nivel geográfico y temporal que permitirá construir el dataset analítico (pueden ayudarse con la Matriz de integración de fuentes que esta publicada en el repo del proyecto)
6. **Construir indicadores socioeconómicos contextuales** a partir de la EPH, agregando la información al nivel geográfico compatible con las Pruebas Aprender (por ejemplo, jurisdicción o aglomerado, según corresponda).
7. **Enriquecer la base de Aprender** incorporando los indicadores contextuales obtenidos de la EPH.
8. **Generar el dataset maestro inicial**, validando la consistencia de la integración y documentando las transformaciones realizadas.

Criterio de selección temporal

Se utilizará la **Encuesta Permanente de Hogares (EPH) correspondiente al tercer trimestre de 2024**, por ser la medición más cercana temporalmente a la aplicación de las **Pruebas Aprender 2024 (octubre)**. Esta decisión busca reducir el desfasaje temporal entre ambas fuentes y mejorar la representatividad de los indicadores socioeconómicos incorporados al análisis.

Producto esperado

Al finalizar esta etapa se deberá contar con:

- Un **dataset maestro inicial** listo para ser utilizado en las siguientes fases del proyecto.
- Un **diccionario de variables** con la descripción y correspondencia entre las variables seleccionadas.
- Un proceso de integración documentado y reproducible que permita actualizar el dataset cuando se incorporen nuevas ediciones de las bases oficiales.

Criterios de aceptación

La primera entrega será considerada completa cuando:

- Se descarguen y documenten las bases de datos de Aprender y EPH.
- Se identifiquen y seleccionen las variables de interés.
- Se justifique la selección de las variables conservadas.
- Se armonicen los nombres y categorías equivalentes entre ambas fuentes.
- Se construya un dataset maestro inicial con las variables definidas.
- El notebook presente una estructura clara, ordenada y reproducible.
- El código sea legible, correctamente documentado y ejecutable de principio a fin sin errores.
- Se incluya una breve conclusión sobre las principales dificultades encontradas y el resultado obtenido.

Requisitos de presentación

El entregable deberá cumplir con las siguientes pautas:

- El desarrollo deberá realizarse en un **notebook de Google Colab (.ipynb)**.
- El notebook deberá contar con una estructura clara, incluyendo:
 - Índice.
 - Secciones y subsecciones correctamente identificadas.
 - Explicaciones que acompañen el desarrollo del código.
- El código deberá seguir buenas prácticas de programación, procurando respetar la **guía de estilo PEP 8** y mantener una estructura legible, modular y documentada cuando corresponda.
- Se recomienda conservar únicamente los análisis y visualizaciones relevantes para los objetivos del proyecto, evitando información redundante.
- Cada análisis o transformación importante deberá finalizar con una breve interpretación o conclusión.
- El notebook deberá compartirse mediante:
 - el enlace directo al archivo de Google Colab, o
 - un repositorio de GitHub con el notebook incluido.
- En caso de utilizar Google Colab, el archivo deberá compartirse con permisos que permitan realizar comentarios para la devolución de la mentoría.

Tips extras

- No eliminen columnas sin justificar la decisión.
- Conserven siempre una copia de los datos originales.
- Documentan todas las transformaciones realizadas.
- Intenten que el notebook pueda ejecutarse de principio a fin (parece obvio, pero muchas veces hay dependencias ocultas).

Repositorio del proyecto

https://github.com/NoeliaFerrero/Proyecto_Mentoria_FAMAF_2026

Fecha límite de entrega

07/08/2026

Feliz comienzo!