

Proyecto:

El Factor D10S: Datos que predicen el abandono escolar antes de jugar el tiempo suplementario

¿Dónde estamos parados?

Ya construimos una primera versión del dataset maestro, integrando información de las Pruebas Aprender con indicadores socioeconómicos provenientes de la EPH.

Ahora oficialmente empieza una de las etapas más fuertes de cualquier proyecto de Ciencia de Datos:

Conocer realmente los datos con los que vamos a trabajar.

Antes de pensar en modelos predictivos, necesitamos entender a fondo con que info contamos, qué calidad presenta, qué patrones aparecen y qué problemas pueden afectar nuestro análisis.

En esta etapa no buscamos "hacer gráficos porque sí". Buscamos usar los datos para encontrar respuestas.

Objetivo

Realizar un Análisis Exploratorio de Datos (EDA) sobre el dataset maestro, identificando:

- características principales de los datos;
- patrones y relaciones relevantes;
- problemas de calidad;
- valores faltantes, inconsistentes o atípicos;
- variables que podrían aportar información para el objetivo del proyecto;
- posibles decisiones de curación que deban realizarse antes del modelado.

La pregunta que guía esta etapa

Nuestro objetivo final es construir un modelo capaz de identificar factores asociados al abandono escolar.

Por lo tanto, durante el EDA intenten preguntarse:

¿Qué características de los estudiantes, las instituciones y el contexto socioeconómico parecen estar relacionadas con el fenómeno que queremos estudiar?

No necesariamente van a encontrar la respuesta todavía.

El objetivo de esta etapa es descubrir qué nos cuentan los datos y qué preguntas nuevas aparecen.

Actividades

1. Conocer el dataset (si todavía no lo hicieron al detalle)

Explorar la estructura general de los datos:

- cantidad de registros y variables;
- tipos de datos;
- variables categóricas y numéricas;
- distribución de las principales variables;
- valores únicos y categorías;
- valores faltantes.

Identificar cualquier característica que les llame la atención.

2. Explorar la calidad de los datos

Buscar problemas que puedan afectar el análisis posterior.

Por ejemplo:

- valores faltantes;
- categorías inconsistentes;
- valores imposibles o sospechosos;
- duplicados;
- valores extremos;
- problemas de tipo de dato;
- variables con poca o ninguna variabilidad.

No se trata solamente de detectar problemas, sino de decidir qué hacer con ellos y justificar la decisión.

3. Explorar relaciones

Analizar relaciones entre las variables que consideren relevantes para el problema.

Algunas preguntas posibles:

- ¿Existen diferencias según sexo, jurisdicción o sector?
- ¿Qué relación aparece entre edad, sobreedad y desempeño?
- ¿Se observan diferencias entre contextos urbanos y rurales?
- ¿Qué características socioeconómicas parecen estar asociadas al rendimiento?
- ¿Hay grupos que presenten comportamientos diferentes?

Estas son solamente preguntas orientadoras. No es necesario responderlas todas y pueden plantear otras.

4. Curar los datos

A partir de lo observado durante el EDA, realizar las transformaciones necesarias para obtener una base

adecuada para las siguientes etapas.

Por ejemplo:

- tratamiento de valores faltantes;
- corrección de inconsistencias;
- recategorización de variables cuando resulte necesario;
- eliminación de registros o variables cuando esté justificado;
- corrección de tipos de datos;
- tratamiento de valores extremos.

Cada decisión de curación deberá estar justificada.

No queremos una base "perfectamente limpia". Queremos una base cuyas decisiones de limpieza podamos explicar.

5. Documentar los hallazgos

Registrar los principales hallazgos obtenidos durante la exploración.

No es necesario documentar absolutamente todo lo que probaron.

Concéntrense en aquello que pueda ser relevante para el proyecto.

Producto esperado

Al finalizar esta etapa deberán contar con:

1. Notebook de EDA

Que permita reproducir el proceso de exploración y curación realizado.

2. Dataset curado

Versión del dataset maestro preparada para continuar con las siguientes etapas del proyecto.

3. Resumen de hallazgos en formato pdf

Una síntesis breve que responda:

¿Qué encontramos en los datos?

¿Qué problemas de calidad detectamos?

¿Qué decisiones de curación tomamos?

¿Qué variables o relaciones parecen especialmente interesantes?

¿Qué nuevas preguntas surgieron?

Importante

No existe un único EDA correcto.

Los dos grupos pueden explorar los mismos datos y llegar a conclusiones un tanto diferentes, ó realizar análisis diferentes como consecuencia de tomar decisiones de curación diferentes.

Lo importante es poder responder:

¿Por qué hicieron lo que hicieron?

En un proyecto real, el EDA no termina cuando se genera el último gráfico.

Termina cuando entendemos suficientemente los datos como para tomar mejores decisiones sobre lo que viene después.

Requisitos de presentación

El entregable deberá cumplir con las siguientes pautas:

- El desarrollo deberá realizarse en un **notebook de Google Colab (.ipynb)**.
- El notebook deberá contar con una estructura clara, incluyendo:
 - Índice.
 - Secciones y subsecciones correctamente identificadas.
 - Explicaciones que acompañen el desarrollo del código.
- El código deberá seguir buenas prácticas de programación, procurando respetar la **guía de estilo PEP 8** y mantener una estructura legible, modular y documentada cuando corresponda.
- Se recomienda conservar únicamente los análisis y visualizaciones relevantes para los objetivos del proyecto, evitando información redundante.
- Cada análisis o transformación importante deberá finalizar con una breve interpretación o conclusión.
- El notebook deberá compartirse mediante:
 - el enlace directo al archivo de Google Colab, 
 - un repositorio de GitHub con el notebook incluido.
- En caso de utilizar Google Colab, el archivo deberá compartirse con permisos que permitan realizar comentarios para la devolución de la mentoría.

Repositorio del proyecto

https://github.com/NoeliaFerrero/Proyecto_Mentoria_FAMAF_2026

Fecha límite de entrega: 04/09/2026